

Layer 18 · single-token steering
400 inputs · mean $\pm$ std

